

V-PEFT × 小样本工业缺陷检测

以 4.15% 的可训参数逼近全量微调——差距与稳定性边界的 3-seed 受控测量

YOLO-Master EsMoE-N · 全参
2.8M

NEU-DET 1800 张 ·
DeepPCB

3 策略 × 3 seed × 同预算

21 训练单元 · 全部 exit 0

先定一场“没有借口的对照”：同预算、3 seed、唯一变量 = 策略

要回答的问题

同等训练预算下，**V-PEFT**(LoRA + planner 自动放置) vs “全量微调 / 冻结主干”——在 2.8M 小模型 + 小样本工业缺陷数据上，精度守住多少、代价几何？

公平协议（怎么保证结论不是器材或运气）

▪ 唯一变量 = 策略：

同预算 epochs=100 · batch=8 · imgsz=640 · amp=false

▪ 不只信一个 seed：

seed 824/2024/777 各 3 个；另加 3 个补充单元做稳定性 / 确定性验证

▪ 指标口径防误导：

best-mAP50(取各 epoch 最优，非末行) · 显存取日志峰值 · 时长 / 单元

▪ 执行可中断可审计：

done 标记 + resume, 8×A800 共享排队, 21/21 exit 0

训练数据：每 (策略 × seed) 使用相同 k=10 全量子集 (184 张)，唯一差异 = 可训练范围与放法

full_sft 全量微调 (基线)

2,813,626 可训 (100%)，整网反传

vpeft V-PEFT + planner

adapter 116,736(4.15%); + 解冻 head
465,250(16.5%)

frozen_backbone freeze=11 冻结主干
1,906,822 可训 (67.8%)

预算相同 → 参数省 95.8%、精度只低 ~0.07(NEU)/~0.11(PCB)

数据集	策略	mAP50 mean±sd	seed 明细 (best)	相对 full
NEU	full_sft	0.767 ± 0.014	0.752 / 0.780 / 0.768	—
NEU	vpeft	0.694 ± 0.052*	0.691 / 0.369△ / 0.746 / 0.644	-0.073
NEU	frozen	0.694 ± 0.041*	0.685 / 0.210△ / 0.659 / 0.739	-0.073
PCB	full_sft	0.989 ± 0.001	0.989 / 0.989 / 0.990	—
PCB	vpeft	0.881 ± 0.072	0.864 / 0.819 / 0.961	-0.108
PCB	frozen	0.769 ± 0.151	0.639△ / 0.891 / 0.907 / 0.639△	-0.220

* NEU vpeft/frozen 为稳健口径 (剔除 1 个偶发 seed, n=3; 全 4-seed 均值 0.612/0.573)
△ = 收敛异常 (seed 偶发或确定性动力学, 详见第 5 页)

“省下来的钱”长什么样

-95.8%

可训参数 : 2.81M → 0.117M

-1.2 G


峰值显存 : 5.3G → 4.2G (A800)

≈ 持平


时长 / 单元 (数据管线为瓶颈)

性价比成立：参数降 95.8%、显存省 1.2G，精度代价在十分位

NEU-DET · mAP50(best, 稳健口径, n=3)



DeepPCB · mAP50(best, 3 seed)



读法 (逐项检验)

① 参数

adapter 只占 4.15%(116,736/2.81M), 为最低约束档; 精度反而高于同预算的冻结 (NEU 稳健口径持平, PCB 高 0.11)

② 精度

NEU 差 -0.07; PCB 差 -0.11 —— 都在 0.1 以内, 且 PCB 全量已趋饱和 (0.989), 压差空间本就小

③ 显存

峰值 - 1.2G(4.2G vs 5.3G), 主要省在冻结 Backbone 梯度; 边缘部署若以显存为约束则红利直接

④ 时长

约持平: 瓶颈是数据管线而非反传, 小模型红利未兑现 —— 报告如实记录, 不把“快”当卖点

⑤ 代价

代价不是参数而是稳定性 (seed 偶发), 见下一页 —— 这是取舍的真正位置

稳定性是隐藏的第三维度：全量全稳，vpeft/frozen 各有 1/4 seed 收敛异常

NEU-DET 逐 seed 分布 (best mAP50, 越靠右越好)

full_sft

vpeft

frozen

0 0.9

● 红 = 收敛异常

验证实验 (3 个补充单元, 全 exit 0)

补充单元	结果 (best)	判定
neu_vpeft_s2025	0.644 正常	s2024 停滞 = seed 偶发
neu_frozen_s2025	0.739 正常	s2024 卡死 = seed 偶发
pcb_frozen_s824b	0.639@ep9 = s824 重跑逐一致	震荡 = 确定性动力学

一句话：参数高效 / 冻结法的“坏 seed”是真实风险

NEU 偶发率 ~1/4(各 1 例), 已由新 seed 验证为 seed 特异而非系统性失效;

PCB frozen@seed824 的震荡 (高点落在 ep9) 同 seed 重跑逐一致 → 是该 (seed, 冻结配置) 的训练动力学事实, 非采样噪声。

→ 单 seed 结论在参数高效法上不可信; 稳定性本身应作为报告维度。

全口径 sd: full 0.014 | vpeft 0.167 | frozen 0.245

剔除 1 个偶发 seed 后: vpeft/frozen sd ≈ 0.04-0.05 —— 异常是“全有或全无”式的坏 seed

Planner 可审计：6/6 ACCEPT、决策跨 seed/ 数据稳定、护栏与缺陷如实

PLACEMENT · 6 个 vpeft 单元

6/6

ACCEPT(无 ADAPT/REFUSE)

planner 每次给出可用放置

每单元一致决策

81 targets

非头层放置

rank = 8

base rank 不升

adapter 116,736

4.15% 全参

465,250 有效可训

含 mismatch 解冻 head

审计点 / 护栏 (逐项可复核)

■ ACCEPT 的语义

状态与 predicted Δ 进入 audit; vpeft 接受后 legacy planner 显式跳过 (ao/dco/mip 被接管)——日志 [V-PEFT] selected ... ranks= 行可 grep

▪ 类别 mismatch(80→6)

检测头重初始化并解冻 → vpeft 有效可训 465,250(16.5%), 报告不混同 adapter 口径

■ strict=True 不降级

任何异常直接 raise(失败即报错), 证据链干净; 未静默 fallback

▪ 缺陷已修 cap<8

0.conv/routing_network.2/dfl.conv 容量 < 最小候选 rank(4): 原先求解器放行 → plan 校验抛错 → V-PEFT 静默降级 legacy; 修复分支已推 fork 并另开上游 PR(C_cap 硬约束 + capacity_excluded 审计), 本报告数据仍是 exclude 规避口径未重跑 → 链接见末页①

■ LOVO / Δ mAP 口径

回归护栏系数与 REFUSE 阈值 (-0.05) 在源码; 实测 Δ 与 predicted_delta 对应关系记入 stage4/p2 笔记

按约束选策略：显存 / 部署受限→ vpeft; 要最高最稳精度→ full; 冻结不划算

场景 A · 显存 / 边缘受限

选 vpeft

理由

4.15% 参数 + 4.2G 峰值显存即达 full 九成以上精度 ($\Delta \leq 0.11$); planner 零调参自动放置。

注意

避免：精度敏感且无力复跑 seed 时

场景 B · 算力充足 · 要最稳精度

选 full_sft

理由

NEU/PCB 均最优且三 seed 零异常 ($sd \leq 0.014$); 免去坏 seed 排查成本。

注意

代价：显存多 1.2G, 参数 2.81M 全反传

场景 C · 少调参的“冻结”方案

不太推荐 frozen

理由

可训参数只省 32%(67.8% 仍在训) 却引入 seed 偶发与确定性震荡 (PCB@824)。

注意

除非工具链强制冻结接口，否则无性价比

判定依据：stage4/README.md 表 1-2(mean/sd/ 配对差) · 表 3(参数 / 显存 / 时长) · 稳健口径定义见同文件

每条结论都给了评审一条可查证的路径（文件 /git/ 复现包）

结论	证据文件（均已入库）	内容
精度与稳定性	stage3_matrix/evidence_summary.csv · runs/*/results.csv	21 单元 best-mAP50 + 逐 epoch 曲线 + 显存峰值
统计 (mean/sd/CI/ 配对差)	stage4_analysis/comparison_tables.md	3-seed 统计 + 稳健口径 + 四维表
Planner 审计	stage4_analysis/planner_audit_summary.md	ACCEPT 分布 / 护栏 / Δ mAP 口径
许可 / SHA / 环境	stage1_env_data/README.md	NEU-DET/DeepPCB 来源与哈希留档
复现一键组装	stage5_pr_delivery/reproduction/	命令样例 · paths.env · 数据转换脚本 · 统计表
缺陷修复 (PR)	分支 fix/vpft-capacity-guard + 独立 PR	C_cap 容量硬约束 + capacity_excluded 审计 + 未适配层冻结 (2 commit · 链接见末页①)

GIT · 8 本地 commit(逐 PR 四节)

- ▶ stage1 env+data
- ▶ stage2 server smoke (BF-01 修复)
- ▶ stage3 matrix + 21 单元
- ▶ stage4 stats + audit
- ▶ stage5 复现包 + 报告 + PPT

一键复现路径

python stage5/assemble_reproduction.py

→ **reproduction/**(命令 / 脚本 /env/ 统计)

三策略命令样例 → 修改 **seed/device**

补充单元 : **run_supplement.py** 自愈调度

边界声明：这些数字为什么不能外推太远（评审先看这里）

样本量 $n = 3\text{-}4$ seed, CI 宽 ($\pm 0.23 \sim 0.34$ 全口径); 偶发率 $\sim 1/4$ 仅作警示, 不推总概率。 n

模型规模 EsMoE-N 全参仅 2.8M: LoRA 相对全量的参数优势被小基数压缩; 结论不必然迁移到更大模型。 M

数据域 两数据集 (工业表面 / PCB 缺陷), 分辨率与类别数有限; NEU-DET 镜像无显式 LICENSE(SHA-256 留档)。 D

预算形态 同 epochs 预算下时长持平 (数据管线瓶颈); 若改为“同 wall-clock”预算, 结论排序可能变化, 未测。 T

策略实现 vpeft= 当前 planner(rank 8/ao solver); frozen=freeze=11 单档, 未扫冻结深度。 S

凡涉及外推 (其他数据 / 更大模型 / 其他预算定义) 均须重测; 本包已备好重测工具链。

一句话带走

V-PEFT 在 2.8M 小模型上的答案：

“低参数 / 低显存拿九成精度 —— 代价写进了 seed 分布里”

三策略一句话结论 (完整对照见 stage4)

full_sft	vpeft	frozen_backbone
0.767 / 0.989 sd ≤ 0.014	0.694* / 0.881 4.15% 参数	0.694* / 0.769 67.8% 可训
最高且最稳的基线；要精度就选它	省 95.8% 参数 +1.2G 显存，接受偶发风险	省得少还添乱，不推荐

交付状态 / 下一步

- ① 修复分支已 push fix/vpeft-capacity-guard(2 commit); 独立 PR 待发起
- ② 证据包已 push fork lycyhrc/YOLO-Master:c3-vpeft-smoke(本地 commit 全部同步)
- ③ 可选扩展 k=5/10/50/100 档位曲线 (数据就绪), GPU 低峰补跑

交付链接 (② 待填 · 上传后替换)

- ① 上游修复 PR 独立发起
Tencent/YOLO-Master/pull/279
- ② 证据附件 <<EVIDENCE_LINK_PLACEHOLDER>>